

Differential Network

High-dimensional differential networks with sparsity and reduced-rank

Mose Park

Department of Statistical Data Science
University of Seoul

Selective. Lab

July 9, 2024

Index

- 1 Remind
- 2 Introduction
- 3 Method
- 4 Simulation

Overview



Graphical
Model

Optimization

Sparsity
Reduced-rank

1

Remind


조건부 독립의 의미

$$P(A \cap B | C) = P(A | C)P(B | C)$$

C가 주어졌을 때 A,B 결합확률

$$P(A | B, C) = P(A | C)$$

정보 B와는 상관없음



정밀 행렬

➤ Graphical Lasso 발표에서,

$$\Theta = \begin{pmatrix} \ddots & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \ddots \end{pmatrix} \rightarrow$$

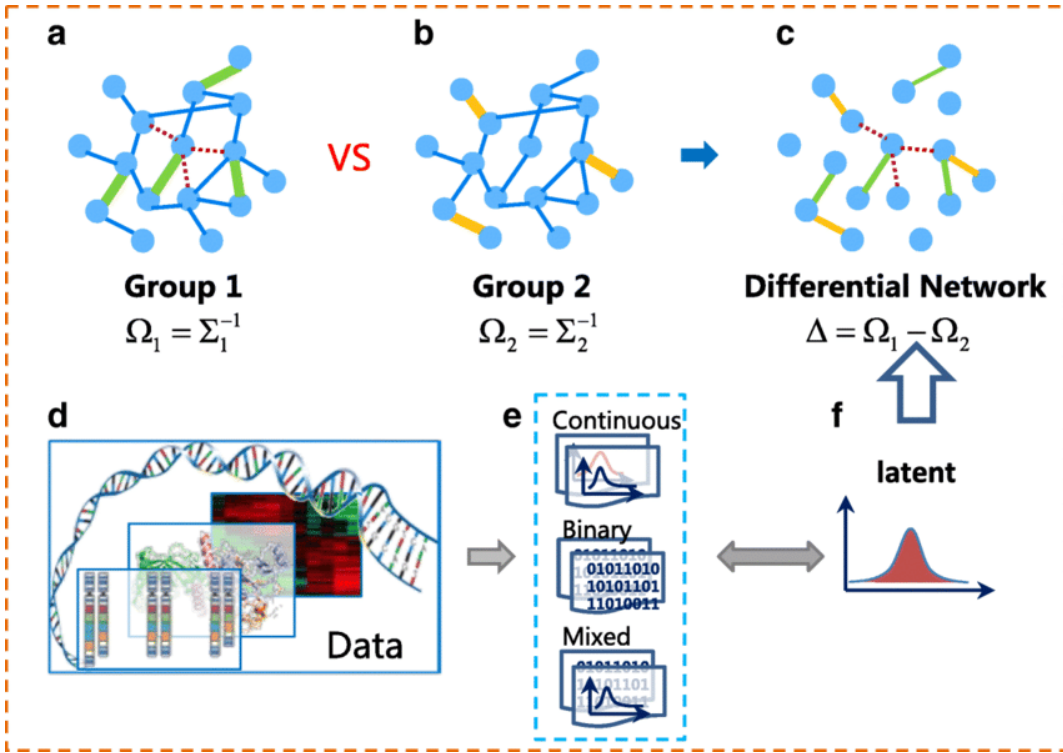
- ✓ X_i 와 X_j 에 해당하는 원소가 0
- ✓ 두 노드 사이의 *edge*는 없음
- ✓ X 가 주어졌을 때, X_i 와 X_j 가 조건부 독립

- $\Theta = \Sigma^{-1}$: 공분산행렬의 역행렬 (정밀 행렬)
- 기본 모델 가정 : $X \sim \mathcal{N}(\mu, \Sigma)$: 다변량 정규분포
- 데이터셋 : $n \ll p$, 고차원 데이터

2

Introduction

모델 소개



➤ Differential Network 이란?

- 각 그룹의 정밀 행렬에 기반하여 그룹 간 상호작용 차이 식별
- 복잡한 변수 관계 모델링 - 생물학, 금융 및 사회과학 등

➤ 선행 연구의 흐름

1. 정밀 행렬을 개별적으로 추정 → graphical lasso
2. Δ 를 직접 추정 → 추정 효율성과 수렴속도 고려하는 연구

- Δ 를 직접 추정하되, sparsity와 reduce-rank를 가정으로 최적화 문제 정의 및 해결

노테이션

➤ Vector Norms

실수 벡터 $\mathbf{a} = (a_1, \dots, a_p)^T \in \mathbb{R}^p$ 에 대해 다음과 같이 노름을 정의합니다:

- ℓ_0 노름:

$$\|\mathbf{a}\|_0 = \sum_{i=1}^p I(a_i \neq 0)$$

- ℓ_1 노름:

$$\|\mathbf{a}\|_1 = \sum_{i=1}^p |a_i|$$

- ℓ_2 노름:

$$\|\mathbf{a}\|_2 = \sqrt{\sum_{i=1}^p a_i^2}$$

- ℓ_∞ 노름:

$$\|\mathbf{a}\|_\infty = \max_{1 \leq i \leq p} |a_i|$$

- 벡터 노름은 익숙한 형태, 원소 기반 행렬 노름은 벡터 노름으로 설명 대체
- 추가로 벡터화에 대한 설명이 있는데, 단순히 행렬의 원소를 하나의 열로 나열하는 것을 의미

➤ Matrix Norm

행렬 A 의 특이값을 $\sigma_1(A) \geq \sigma_2(A) \geq \dots \geq \sigma_{\min(p,q)}(A) \geq 0$ 로 나타내면, 다음과 같은 노름을 정의할 수 있습니다:

- 스펙트럴 노름:

$$\|A\| = \sigma_1(A) = \sup_{\|\mathbf{x}\|_2 \leq 1} \|A\mathbf{x}\|_2$$

- 누클리어 노름:

$$\|A\|_* = \sum_{i=1}^{\min(p,q)} \sigma_i(A)$$

- 프로베니우스 노름:

$$\|A\|_F = \sqrt{\sum_{i=1}^{\min(p,q)} \sigma_i^2(A)} = \sqrt{\sum_{i,j} a_{ij}^2}$$

➤ Kronecker product

$$A = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix}$$

$$A \otimes B = \begin{pmatrix} 1 \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} & 4 \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} \\ 2 \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} & 5 \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} \\ 3 \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} & 6 \begin{pmatrix} 1 & 0 \\ 2 & 3 \end{pmatrix} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 4 & 0 \\ 2 & 3 & 8 & 12 \\ 2 & 0 & 5 & 0 \\ 4 & 6 & 10 & 15 \\ 3 & 0 & 6 & 0 \\ 6 & 9 & 12 & 18 \end{pmatrix}$$



- ✓ 두 행렬 A와 B의 모든 조합에 대해 곱
- ✓ 외적의 특수한 형태

- 기억해야할 부분은 벡터화는 크로네커 곱과 호환이 된다. (호환성) $\longrightarrow \text{vec}(ABC) = (C^T \otimes A)\text{vec}(B)$

아이디어의 관점

➤ 이론적 관점

$$\|\Delta^*\|_0 = o\left(\sqrt{\frac{n_1+n_2}{\log p}}\right)$$

* 일반적으로 sparsity의 조건이 위와 같음

$$o\left(\sqrt{\frac{n_1+n_2}{\log p}}\right)$$

$\text{rank}(\Delta^*) \leq \|\Delta^*\|_0$ 이므로 추정량의 rank가 sparsity 조건보다 작아야 함

➤ 방법론적 관점


$$X^T \Delta^* X = \sum_{i=1}^d \lambda_i (u_i^T X)^2$$

* 행렬 분해를 통해 추정


→ latent factor 식별

- n 이 각각 100이고 $p = 1000$ 인 경우 0이 아닌 요소는 약 5.39보다 빠르게 증가해서는 안됨 → 매우 sparse 함

$$\text{rank}(\Delta^*) \leq \|\Delta^*\|_0$$



Spam data



Single-cell data

- 0이 아닌 요소와 특이값의 수 모두 sparse함에 따라 점차 감소하는 경향을 보임
- 단일 세포 데이터에서 더 많은 0이 아닌 요소가 있는 것으로 보아 데이터가 더 복잡하고 고차원적 특성을 가짐

3

Method

방법 1

➤ Based on Lasso $\longrightarrow b = \text{vec}(\Delta)$

$$\text{argmin}_{b \in \mathbb{R}^{p^2}} \left(\frac{1}{2} b^T (\hat{\Sigma}_1 \otimes \hat{\Sigma}_2) b - b^T \text{vec}(\hat{\Sigma}_1 - \hat{\Sigma}_2) + \lambda \|b\|_1 \right)$$

우리가 직접 추정해야할 식 (1) 에서

$$\Delta^* = \Sigma_2^{-1} - \Sigma_1^{-1} = \Sigma_1^{-1}(\Sigma_1 - \Sigma_2)\Sigma_2^{-1}$$

$$\longrightarrow \text{vec}(\Delta^*) = (\Sigma_2 \otimes \Sigma_1)^{-1} \text{vec}(\Sigma_1 - \Sigma_2)$$

* 우리가 모르는 것

- 식 (1)에서 출발해 2차식 형태의 목적식을 다음과 같이 정의할 수 있다.
- 우리가 추정하는 것을 sparse하게 함 - Graph 구조 자체를 sparse하게 해서 유의미한 관계 식별

방법 2

참고 : "A direct approach for sparse quadratic discriminant analysis", Jiangetal. (2018)

➤ QDA

$$\hat{\Delta}_{\text{QDA}} = \underset{\Delta \in \mathbb{R}^{p \times p}}{\operatorname{argmin}} \left(\frac{1}{2} \operatorname{tr}(\Delta^T \hat{\Sigma}_1 \Delta \hat{\Sigma}_2) - \operatorname{tr}(\Delta \hat{\Sigma}_1 \hat{\Sigma}_2) + \lambda_1 \|\Delta\|_1 \right) \quad (2)$$

우리가 직접 추정해야할 식 (1) 에서

* 교환법칙이 자유로움

$$\Sigma_2 \Delta \Sigma_1 = \Sigma_1 \Delta \Sigma_2 = \Sigma_1 - \Sigma_2 \longrightarrow \frac{1}{2} \operatorname{tr}(\Delta^T \Sigma_1 \Delta \Sigma_2) - \operatorname{tr}(\Delta(\Sigma_1 - \Sigma_2))$$

- 식 (1)에서 출발해 2차식 형태의 목적식을 trace 성질과 함께 정의할 수 있다.

방법 3

참고 : "Differential network analysis via lasso penalized d-trace loss", Yuanetal. (2017)

➤ Dtrace

$$\hat{\Delta}_{\text{Dtrace}} = \underset{\Delta \in \mathbb{R}^{p \times p}}{\operatorname{argmin}} \left(\frac{1}{4} \operatorname{tr}(\Delta^T \hat{\Sigma}_1 \Delta \hat{\Sigma}_2) + \frac{1}{4} \operatorname{tr}(\Delta^T \hat{\Sigma}_2 \Delta \hat{\Sigma}_1) - \operatorname{tr}(\Delta \hat{\Sigma}_1 \hat{\Sigma}_2) + \lambda \|\Delta\|_1 \right)$$

우리가 직접 추정해야할 식 (1) 에서 대칭성도 고려

$$\Sigma_2 \Delta \Sigma_1 = \Sigma_1 \Delta \Sigma_2 = \Sigma_1 - \Sigma_2$$

- 대칭성도 고려하여 문제를 좀 더 쪼개서 접근

제안

$$\hat{\Delta} = \operatorname{argmin}_{\Delta \in \mathbb{R}^{p \times p}} \left(\frac{1}{2} \operatorname{tr}(\Delta^T \hat{\Sigma}_1 \Delta \hat{\Sigma}_2) - \operatorname{tr}(\Delta \hat{\Sigma}_1 \hat{\Sigma}_2) + \lambda_1 \|\Delta\|_1 + \lambda_2 \|\Delta\|_* \right) \quad (3)$$

$$\|\Delta\|_* = \sum_i \sigma_i(\Delta) \quad \longrightarrow \quad \Sigma = \begin{pmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{pmatrix} \quad \xrightarrow{\text{red circle}} \quad 0 \text{ 이 된다면 rank는 감소}$$

- nuclear norm의 경우 특이값의 합을 최소화 하려고 함
- 즉, 행렬의 rank를 감소시키는 효과 발생
- reduced 된 rank를 통해 저차원 구조로 해석력과 근본적인 구조를 볼 수 있다.

알고리즘

$$\begin{aligned} \min_{\Delta_1, \Delta_2, \Delta_3} \quad & \frac{1}{2} \text{tr}(\Delta_1^T \hat{\Sigma}_1 \Delta_1 \hat{\Sigma}_2) - \text{tr}(\Delta_1 (\hat{\Sigma}_1 \hat{\Sigma}_2)) + \lambda_1 \|\Delta_2\|_1 + \lambda_2 \|\Delta_3\|_* \\ \text{s.t.} \quad & \Delta_1 = \Delta_2 = \Delta_3 = \Delta \end{aligned} \quad (4)$$

위 선형 제약식을

$$(\Delta_1, \Delta_2, \Delta_3)^T - (I_p, I_p, I_p)^T B = 0 \quad \text{로 표현} \quad \rightarrow \quad \text{왜? 어떻게?}$$

- 목적식과 선형 제약조건이 총 3가지로 복잡함 \longrightarrow 부분 문제로 나눠서 해결하고 갱신
- ADMM 알고리즘

* Scaled augmented Lagrangian

- 제약조건을 위반하기 어렵게 만드는 역할, ρ 는 step size

$$L(\cdot) = \frac{1}{2} \text{tr}(\Delta_1^\top \hat{\Sigma}_1 \Delta_1 \hat{\Sigma}_2) + \lambda_1 \|\Delta_2\|_1 + \lambda_2 \|\Delta_3\|_* + \frac{\rho}{2} \sum_{j=1}^3 \|\Delta_j - \Delta + A_j\|_2^2$$

➤ Step 1. $(\Delta_1^{k+1}, \Delta_2^{k+1}, \Delta_3^{k+1}) = \arg \min_{\Delta_1, \Delta_2, \Delta_3} L(\Delta_1, \Delta_2, \Delta_3, \Delta^k, A_1^k, A_2^k, A_3^k)$

➤ Step 2. $\Delta^{k+1} = \arg \min_{\Delta} L(\Delta_1^k, \Delta_2^k, \Delta_3^k, \Delta, A_1^k, A_2^k, A_3^k) = \frac{1}{3} \sum_{j=1}^3 (\Delta_j^{k+1} + A_j^{k+1})$

➤ Step 3. $(A_1^{k+1}, A_2^{k+1}, A_3^{k+1})^T = (A_1^k, A_2^k, A_3^k)^T + (\Delta_1^{k+1}, \Delta_2^{k+1}, \Delta_3^{k+1})^T - (I_p, I_p, I_p)^T \Delta^{k+1}$

- 1단계는 주어진 라그랑지안 loss로 Δ 1,2,3 을 업데이트
- 2단계는 Δ 자체를 위의 값과 보조 변수(Auxiliary Variable) A 를 활용해 업데이트 (평균으로 계산)
- 3단계는 보조변수 값들을 업데이트

Sub problem

$$\left\{ \begin{aligned} \Delta_1^{k+1} &= \arg \min_{\Delta_1} \left\{ \frac{1}{2} \text{tr}(\Delta_1^\top \hat{\Sigma}_1 \Delta_1 \hat{\Sigma}_2) - \text{tr}(\Delta_1^\top \hat{\Sigma}_1 \hat{\Sigma}_2) + \frac{\rho}{2} \|\Delta_1 - \Delta^k + A_1^k\|_2^2 \right\} \\ \Delta_2^{k+1} &= \arg \min_{\Delta_2} \left\{ \lambda_1 \|\Delta_2\|_1 + \frac{\rho}{2} \|\Delta_2 - \Delta^k + A_2^k\|_2^2 \right\} \\ \Delta_3^{k+1} &= \arg \min_{\Delta_3} \left\{ \lambda_2 \|\Delta_3\|_* + \frac{\rho}{2} \|\Delta_3 - \Delta^k + A_3^k\|_2^2 \right\} \end{aligned} \right.$$

Solution

$$\left\{ \begin{aligned} \Delta_1^{k+1} &= B_1 \left(\Lambda \circ \left(B_1^\top (\hat{\Sigma}_1 - \hat{\Sigma}_2 + \rho \Delta^k - \rho A_1^k) B_2 \right) \right) B_2^\top \\ \Delta_2^{k+1} &= \text{soft}(\Delta^k - A_2^k, \frac{\lambda_1}{\rho}) \\ \Delta_3^{k+1} &= \sum_{i=1}^p \text{soft}(d_i, \frac{\lambda_2}{\rho}) u_i v_i^\top \end{aligned} \right. \longrightarrow \text{soft threshold 연산을 통해 해를 구함 (norm 계산 때문)}$$

* Λ_i : 고유값 분해 대각행렬
 * Λ = 두 그룹의 고유값의 역수

- 참고 논문의 명제 1에 의해 목적식의 해가 증명이 되어있습니다.
- 풀이를 간단하게 설명드리면, 목적식의 도함수를 계산하고 벡터화 호환성과 SVD 사용해 계산할 수 있는 품으로 유도

이론적 분석

* 정리 1 \longrightarrow 제안하는 추정의 정확도와 일관성을 보장

가정 (A1)부터 (A4)가 성립하고, λ_1 과 λ_2 가 다음을 만족한다고 가정합니다:

$$2c_1\sqrt{\frac{\log p}{n}} \leq \lambda_1 \leq 3c_1\sqrt{\frac{\log p}{n}}, \quad \lambda_2 \leq c_2\lambda_1$$

여기서 c_1 는 양의 상수이고, c_2 는 충분히 작은 상수입니다. 그러면, 충분히 큰 상수 $C > 0$ 가 존재하여 다음을 만족합니다:

$$\|\hat{\Delta} - \Delta^*\|_2 \leq C\sqrt{\frac{s \log p}{n}}, \quad \|\hat{\Delta} - \Delta^*\|_1 \leq Cs\sqrt{\frac{\log p}{n}}$$

확률이 $1 - p^{-1}$ 보다 클 때.

- ✓ X_1 과 Y_1 은 sub gaussian random vector
- ✓ 두 가우시안 분포의 모멘트에 대한 정규화 조건
- ✓ Δ^* 는 sparse하다.
- ✓ Δ^* 는 low-rank

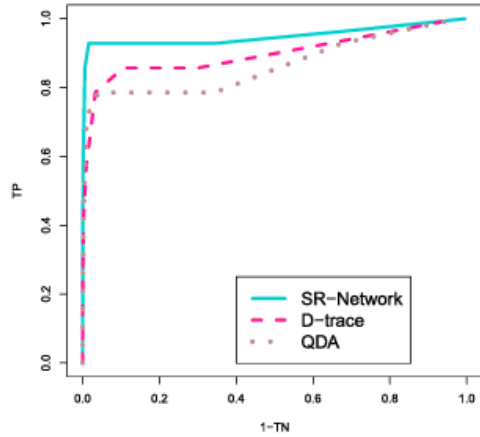
- 가정 2의 경우 표본의 비율을 통해 그룹간 적절한 비율을 유지함.
- 그리고 공분산 행렬의 조건수를 특정 상수로 제한해 조건수가 지나치게 커지는 것을 방지
- "가정이 많은데, 추정이 어느정도로 잘 한건지 비교가 어려웠음"

4


Simulation

시뮬레이션 데이터

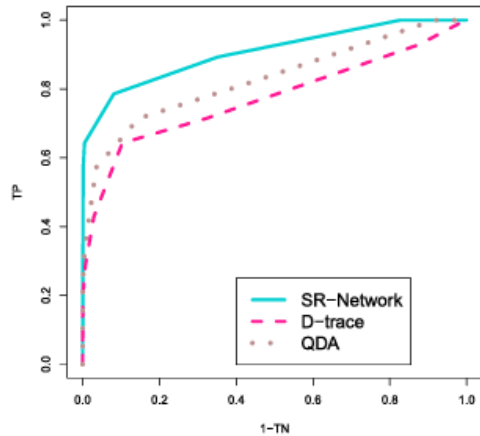
* ROC 커브




(a)



(b)



(c)




(d)


- $p = 50, 100, 120, 150$
- $X_1, \dots, X_{n_1} \sim N(0, \Sigma_1)$
- $Y_1, \dots, Y_{n_2} \sim N(0, \Sigma_2)$
- $n = 100$

- 제안하는 방법이 다른 방법에 비해 우수
- 하지만, $p \gg n$ 인 세팅인 (d)에서 과적합으로 보이는데, 확실히 고차원 구조에서 추정이 어렵다는 것을 느꼈음


실제 데이터 - 스팸메일



(a) SR-Network



(b) D-trace

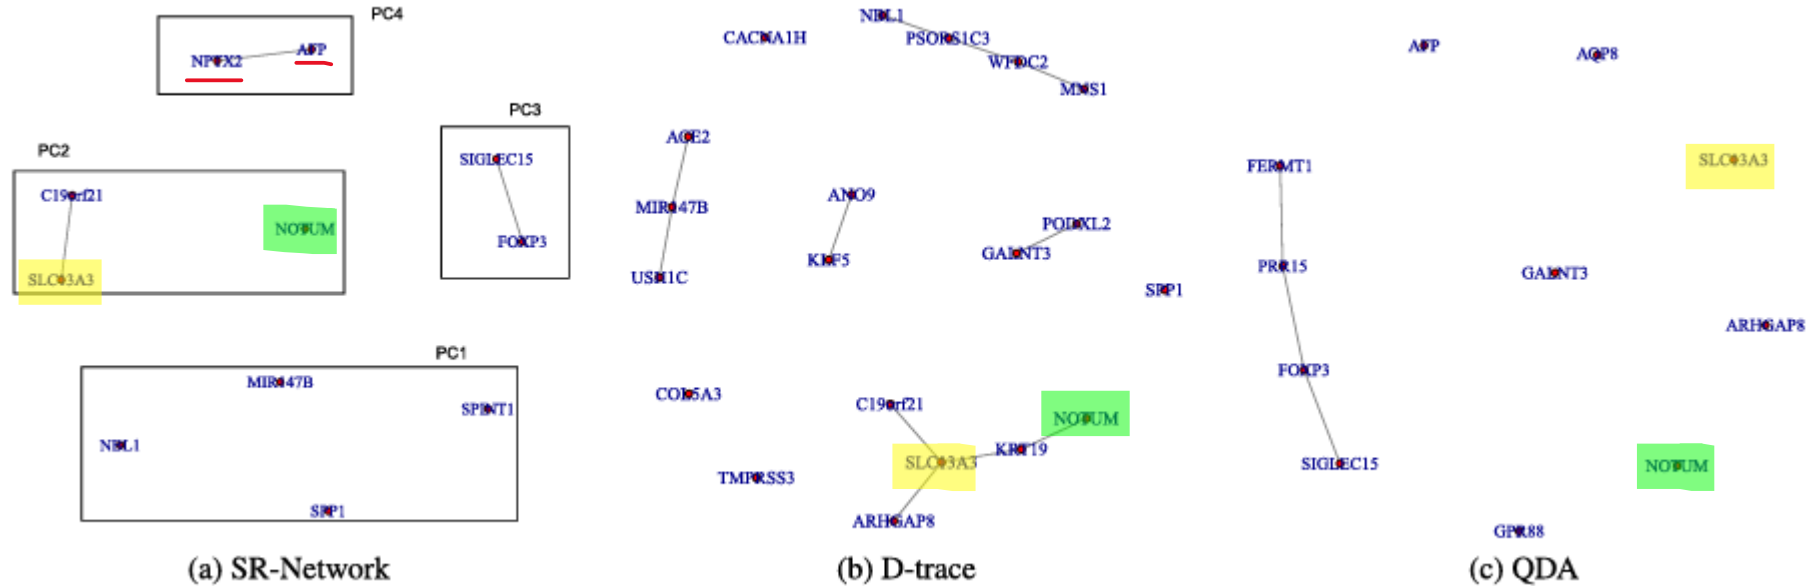


(c) QDA

- 데이터셋의 경우 1813개의 스팸, 2788개의 스팸이 아닌 이메일을 56개의 변수로 구성
- 위 그림에서 재미있는 스팸인지 구분해낼 수 있는 잠재 요인을 식별
 - 특정 키워드
 - 메일 텍스트의 길이 등
 - HP 연구소에서 보낸 이메일

실제 데이터 - 간암 유전자 데이터

* 다른 방법은 잘 못찾지만 새로운 발견



- 첫 4개의 주성분(PCs)이 특정 유전자들에 대해 유의미한 계수를 가짐

- 형광펜은 기존 간암과 관련된 의미있는 유전자로 밝혀진 부분들 (모든 모델이 캡처)
- 하지만, 제안된 방법으로 latent factor를 캡처해 추가 연구에 대한 도움을 줄 수 있다.